

# Datorlaboration 1

Josef Wilzén

August 21, 2024

732G12 Data Mining HT2021

## Allmänt

Datorlaborationerna kräver att ni har R och Rstudio installerat.

- **ISL**: An Introduction to Statistical Learning,
  - Boken: [länk](#)
  - R-kod till labbar: [länk](#)
  - Dataset: [länk](#) och [länk](#)

Notera att ni inte behöver göra alla delar på alla uppgifter. Det viktiga är att ni får en förståelse för de olika principerna och modellerna som avhandlats. Dessa uppgifter ska inte lämnas in, utan är till för er övning.

## R-kod

- R-paketet `glmnet` implementerar Ridge, LASSO och elastic-net: bra intro [här](#) och [här](#).
- Kodmanual för kursen finns [här](#). Notera att denna inte är uppdaterad för detta års omgång, så mindre ändringar kan komma senare.

## Frivillig repetition: Logistik regression

1. Gå igenom laborationerna 4.7.1 och 4.7.2 i **ISL**.

## 1 Modelval och Cross-Validation

1. Gå igenom laborationerna 5.3.1, 5.3.2, 5.3.3 i **ISL**.
2. **ISL** 5.4 Exercises Conceptual: Gör uppgift 3)

## 2 Variabelselektion för linjära modeller

1. Gå igenom laborationen 6.5.1 i **ISL**.
2. Gå igenom laborationen 6.5.2 i **ISL**.
3. Gå igenom koden här för att testa adaptive lasso.
4. **ISL 6.6 Exercises Conceptual:** Gör uppgift 2) och 4)

## 3 Variabelselektion för logistik regression

1. Gå till UC Irvine Machine Learning Repository, länk [här](#).
2. Ni ska nu välja ut ett dataset här som passar för klassificering. Notera att ni kan filtrera på olika kategorier till vänster. Ni kan sortera olika kolumner genom att trycka på kolumnnamnet.
3. Välj ett dataset som intresserar er, dock ej för stort, då det kan resultera i långsamma beräkningar. Nedan följer några förslag, men välj gärna andra:
  - (a) Divorce Predictors data set Data Set
  - (b) Wine Data Set
  - (c) Heart failure clinical records Data Set
4. Försök förstå (kort) vad datasetet handlar om och vad de olika variablerna innebär. Kolla om responsvariabeln är binär (logistic regression) eller nominell (multinomial regression), detta avgör vilken typ av modell ni ska använda.
5. Ladda ner datasetet och importera till R. Notera att många dataset kommer i något komprimerat format.
6. Genomför nödvändig datahantering, tex: kolla efter NA, skala om variabler, enkla plottar beskrivande statistik mm.
7. Skapa ett testset från ert dataset (vissa dataset har en förbestämt testset andra inte).
  - (a) Se till att alla klasser för responsvariabeln finns representerade i testsetet
  - (b) `createDataPartition()` i från paktet `caret` kan skapa träning-test delning. Se kodmanualen.
8. Nu ska ni bygga en prediktiv modell (logistik regression) som kan prediktera observationer i testdata. Testa följande metoder för modellval:
  - (a) Manuellt välja en delmängd av alla variabler och skatta som “vanligt” med `glm()` eller liknade funktion. Lägg inte för lång tid på att välja variabler.

- (b) Forward selection
  - (c) Ridge regression med korsvalidering för  $\lambda$ . Tips: `cv.glmnet()`.
  - (d) LASSO regression med korsvalidering för  $\lambda$
  - (e) Elesticnet regression, med  $\alpha = 0.5$  och korsvalidering för  $\lambda$ .
9. Räkna ut klassificeringsfelet (misclassification rate) för testdata. Vilken model var bäst? Undersök om det är lätt att identifiera vilka variabler som är viktiga för modellerna. För den bästa och näst bästa modellen:
- (a) Beräkna förväxlingsmatrisen för testdata. Se kodmanualen för kod.
  - (b) Beräkna sensitivitet och specificitet för testdata.
  - (c) Vad skiljer den bästa och näst bästa modellen när det gäller klassificeringen? Är det stor eller liten skillnad?
  - (d) Vilka variabler var viktiga för bästa och näst bästa modellen när det gäller prediktion? Är det någon skillnad?

## 4 Mer övningsuppgifter

Nedan följer fler övningsuppgifter.

- Kapitel 5.4: Exercises Applied: 5), 7), 8)
- Kapitel 6.6: Exercises Applied: 8), 10)