Korsvalidering: slutgiltig modell

Säg att ni har två olika modeller (tex linjär regression med två olika antal förklarande variabler) och ett dataset. Då kan korsvalidering användas för att avgöra vilken modell som troligen kommer att fungera bäst på ny liknande data (testdata). Med "modell" menar vi typen, den övergripande strukturen, eller att modellerna är av samma typ men har olika hyperparametrar. I detta fall är hyperparametern antalet förklarande variabler. Med "modell" menar vi inte här "specifika parameterskattningar för ett visst dataset för en modell".

Efter att ha gjort korsvalidering så visar det sig att den ena modellen har lägre genomsnittligt korsvalideringsfel, då väljer vi den som vår slutgiltiga modell.

Notera att i korsvalidering så skattade vi den modellen k olika gånger och har k olika uppsättningar med parameterskattningar för den modellen. Dessa kommer vi inte använda vidare efter att vi har valt den modell med lägst genomsnittligt korsvalideringsfel. Istället så skattar vi om modellen som vi valde på all träningsdata, och detta blir vår slutgiltiga modell som vi använder vid prediktioner eller inferens. Vi kan även använda den för att skatta generaliseringsfel på testdata.